

Modelo de sensibilidad del riesgo sistémico en variables endógenas del sistema financiero

ELABORADO POR ELIAS PREZA *

eliaspreza@gmail.com

5 de enero de 2020

Resumen

El monitoreo y vigilancia de la estabilidad del sistema financiero es importante para la reducción del riesgo sistémico, esta modesta investigación pretende exponer en forma de un modelo econométrico la sensibilidad de algunas variables endógenas del sector financiero que impactan en menor o mayor grado a la liquidez de todo el sistema, dando como principales hallazgos que el riesgo sistémico aumenta cuando aumentan los ratios de inmovilidad patrimonial y la alta morosidad, aumenta el riesgo cuando la liquidez neta de los bancos se contrae, además se evidencia que la liquidez se incrementa si el riesgo crediticio aumenta, sin embargo, no es sano a largo plazo porque incrementa el riesgo sistémico, otro de los hallazgos importantes es que la concentración de la estructura del sistema financiero podría propiciar un alto contagio o propagación de una crisis, por ejemplo son 4 bancos quienes concentran el 65%, de los depósitos, lo interesante que resalta la investigación también es que dos cuartas parte de los bancos concentra el 80%, de los activos financieros, lo que equivale al 77%, de liquidez de toda la economía.

1. Introducción

La presente investigación pretende exponer de forma técnica la medición de la sensibilidad del impacto de variables endógenas del sistema financiero, a través de una herramienta econométrica no concluyente pero que aporta insumos importantes para la detección de un riesgo sistémico. La investigación en su segunda parte expone un marco de referencia y hace una breve descripción teórica del riesgo sistémico. Como tercer apartado se describe de forma general la metodología empleada, es importante destacar que el modelo fue desarrollado con una potente herramienta de análisis PYTHON, con el uso de librerías muy robustas y ahora con aplicaciones en el área financiera; se describen los supuestos del modelo y la sustentación técnica matemática del modelo de regresión múltiple. En los

supuestos del modelo es clave agregar que este destaca un aporte complementario y da pie a la búsqueda de nuevos modelos para la construcción de un indicador con mayor capacidad de predicción multidimensional y con mayor frecuencia periódica a medida exista disponibilidad de los datos. Como cuarto apartado se muestran los resultados resumen del modelo, así como todas las pruebas y test de comprobación de los supuestos para estimar o predecir. Finalmente en el apartado de la discusión, se exponen de manera sustentada los principales hallazgos de las tendencias del modelo con respecto a las variables explicativas y el resultado de un escenario hipotético aplicando la capacidad predictiva del modelo. Se explica como las variables de patrimonio, liquidez neta, morosidad y riesgo crediticio impactan de forma positiva o negativa en la liquidez financiera de toda la economía.

*Especialista en estadística aplicada

2. Riesgo Sistémico

2.1. Definición del riesgo sistémico

Se hace referencia en éste apartado teórico de las citas empleadas en la investigación de [Angulo Duque, 2015], entendiendo en las primeras definiciones que se empleaban del concepto de riesgo sistémico para describir únicamente el pánico bancario y las etapas de recesión. Actualmente, debido a la desintermediación financiera, se considera el sistema financiero en su conjunto:

- En primer lugar en 1994 la definición del Bank for International Settlements BIS refiriéndose “al riesgo de que la quiebra de un participante pueda originar quiebras en otros participantes.”.
- En segundo lugar, el G-10 en 2001 lo definió como: “el riesgo de que un evento desencadene pérdidas económicas de valor o confianza, aumentando la incertidumbre sobre el sistema financiero y generando efectos adversos en la economía real.”
- En tercer lugar, en 2009, Ben Bernanke, presidente de la reserva federal americana, en una carta relacionó el riesgo sistémico con: “acontecimientos que amenazan a la estabilidad del sistema financiero en su conjunto y como consecuencia a la economía en general, no a una o a dos instituciones”.
- En cuarto lugar, en 2010, Billio y otros definieron el riesgo sistémico como: “el generado por una serie de quiebras correladas de instituciones financieras durante un corto periodo de tiempo reduciendo la liquidez y aumentando la desconfianza del sistema financiero en su conjunto”.
- Mientras, la normativa europea CRD IV¹ concreta la definición como: “el riesgo de que una perturbación del sistema financiero pueda entrañar perjuicios graves para el sistema financiero y la economía real.”.

2.2. Características del riesgo sistémico

La crisis sistémica aparece a partir de un evento denominado sistémico, este puede ser exógeno (fuera del sistema financiero) o endógeno (dentro del sistema financiero), y es el desencadenante de una serie de acontecimientos sucesivos, a menudo denominado como efecto dominó. Se hace visible a través de complicaciones en el funcionamiento del sistema financiero y la economía real. Este impacto será más contundente cuando algún intermediario quiebre o algún mercado deje de operar. La severidad o impacto de un evento sistémico se evalúa a través del impacto sobre el consumo, la inversión, el crecimiento económico y el bienestar. Para analizarlo existen dos perspectivas: la horizontal que centra su atención en el sistema financiero y la vertical que tiene en cuenta tanto el sistema financiero como a la economía real. El BIS en su informe anual de 2009 recoge como principales fuentes de riesgo sistémico:

- Instrumentos (crédito, bonos, acciones y derivados), su opacidad complejidad y abundancia de contratos dificultan la correcta valoración y evaluación del riesgo. Además en las fases de auge prolifera la innovación financiera, creando riesgos ocultos e infravalorados, aumentando la prociclicidad del sistema financiero.
- Mercados organizados y en mercados no organizados, en periodos de tensión se exigiría aumentar las garantías por riesgo de contraparte, amplificando el efecto cíclico.
- Instituciones (entidades de crédito, empresas de servicios de inversión, compañías de seguros y fondos de pensiones) debido a exposiciones comunes y la interdependencia entre ellas. Dicho de otra manera un sector financiero con unas pocas instituciones grandes puede entrañar el mismo riesgo que otro formado por muchas instituciones pequeñas con balances similares.

Para entender la complejidad de este fenómeno el Banco Central Europeo describe en su informe de

¹Directiva 2013/36/UE del parlamento europeo y del consejo de 26 de junio de 2013 relativa al acceso a la actividad de las entidades de crédito y a la supervisión prudencial de las entidades de crédito y las empresas de inversión

estabilidad financiera de 2009, tres posibles formas de manifestación del riesgo sistémico:

- **Riesgo de contagio:** Pánico bancario, si los depositantes no están informados adecuadamente y actualizan sus expectativas de la salud financiera de sus propios bancos a partir de la observación de otros bancos; Mercado interbancario, los bancos usan el mercado interbancario para intercambiar riesgos entre ellos, surgiendo el riesgo de contagio, a través de las exposiciones que los bancos mantienen en estos mercados; Selección adversa, derivada de la asimetría de información. Los bancos no son capaces de identificar o evaluar correctamente los riesgos que asume; Sistema de pagos, a través de posiciones expuestas, como pueden ser los derivados OTC.
- **Riesgo de shocks macroeconómicos:** hace referencia a un evento exógeno, que se materializa en el activo, mientras el pasivo permanece inalterado.
- **Formación de desequilibrios en el sistema financiero:** hace referencia a los comportamientos pro-cíclicos de las épocas expansivas, formando desequilibrios debido al aumento del apetito al riesgo. El Banco Central Europeo justifica cuatro razones por las que se forman los desequilibrios: (1) Efecto manada, hay un comportamiento de los intermediarios y agentes a imitarse entre sí, haciendo frente a los mismos riesgos, (2) Los intereses bajos, fomenta la admisión de riesgos más altos para obtener una mayor rentabilidad, (3) Tendencia a apalancarse durante épocas expansivas y (4) Riesgo moral, los grandes bancos pueden realizar estrategias más arriesgadas o a precios más competitivos, ya que si entran en quiebra serán rescatados por las autoridades públicas.

Continuando con el riesgo de formación de desequilibrios en el sistema financiero, una vez que un

evento se convierte en sistémico se canaliza hacia la economía real a través de:

- Distorsiones en los sistemas de pagos.
- Distorsiones en los flujos de crédito.
- Colapso de los precios de los activos.

Desde un punto de vista del riesgo sistémico no es tan importante la caracterización jurídica de una institución o mercado es sistémico, si no si su fallo afectaría a la estabilidad financiera. No obstante, fallos en instituciones o mercados no significativos sólo afectarían cuando fallen muchas a la vez.

[Hansen, 2013]² en su artículo “Challenges in identifying and measuring systemic risk” matiza la diferencia entre riesgo sistemático y riesgo sistémico, debido a la confusión existente entre ambos conceptos y su importancia para una correcta gestión e interpretación. Cuando un inversor se expone conscientemente al riesgo sistemático [Betancourt Bejarano et al., 2013]³ exige una rentabilidad mayor a la del activo sin riesgo. El objetivo de las autoridades está en crear un ambiente de seguridad para fomentar la inversión y el minimizar el impacto de shocks macroeconómicos mediante políticas fiscales y monetarias.

La exposición al riesgo sistémico no es remunerada y surge como una externalidad. Por ello las autoridades deben prevenir su aparición y limitar su expansión mediante regulación.

3. Metodología del Modelo

3.1. Herramienta de análisis

Para la construcción del modelo econométrico se emplea una potente herramienta de análisis científico y estadística como lo es el lenguaje de programación **Python Versión 3.0** aplicando la sintaxis del modelo en la herramienta **JUPYTER Notebook** ver en anexo el cuaderno de la arquitectura del modelo

²Peter Hansen, L. (2013) Challenges in identifying and measuring systemic risk. CEMFI working paper No. 1305.

³Riesgo que no se puede eliminar a través de la diversificación. Markowitz, H.(1952) Portfolio selection. Journal of Finance, vol.7, No. 1, pp.77-91

planteado, dicho Notebook se corrió en el programa para analítica avanzada de datos **ANACONDA**. La ventaja de aplicar esta potente herramienta es que esta condicionada para correr en un ambiente complejo de compilación de datos como el **Big Data y el Machine Learning**, herramientas que empiezan a tener una amplia aplicación en las áreas financieras, teniendo mayor auge en la construcción de modelos de las variables más críticas; una guía muy completa del uso de la programación en Python se puede encontrar en [VanderPlas, 2016].

3.2. Proceso de determinación del modelo

Los pasos en el proceso de la determinación del modelo fueron los siguientes:

1. Preparación de la base de datos con los principales indicadores de los ratios financieros bancarios, así como variables económicas y financieras.
2. Revisión de la consistencia de la base de datos en la serie de datos establecida.
3. Análisis de las correlaciones parciales y bivariadas para identificar cuales de ellas pueden determinar las variables explicadas y explicativas.
4. Se seleccionan las variables explicativas a partir de las correlaciones parciales con respecto a la variable dependiente.
5. Corrida del modelo con las variables con mayores correlaciones entre sí.
6. Conforme a las primeras pruebas de significancia del modelo se depuran las variables que formaran el core de la variable explicada.
7. Se desarrollan las transformaciones o ajustes a las variables conforme a los hallazgos de las primeras pruebas de los supuestos.
8. Se corren todas las pruebas de los supuestos del modelo para saber su robustez para estimar.
9. Se analizan los escenarios de estimación de la variable explicada con ajustes arbitrarios a las variables explicativas para medir el impacto.

3.3. Supuestos y consideraciones al modelo

Como en todo modelo, se deben determinar los supuestos teóricos para una correcta interpretación de los estimados:

- **El modelo no es completamente concluyente:** es importante destacar este hecho debido a que se debe continuar ejecutando más pruebas de ajuste y revisión de variables que provienen de indicadores financieros que por lo general a lo largo del tiempo pueden sufrir ciertos arreglos en los cálculos a través de una nueva normativa emanada por el ente regulador y esto puede cambiar la tendencia del modelo.
- **El resto de todas las variables permanecen constantes:** las estimaciones resultantes por el modelo cuentan con el supuesto de que el resto permanecen constantes y solo se encuentran influenciadas por el error aleatorio.
- **Las variables exógenas fueron excluidas del modelo por la alta correlación a la liquidez:** se excluyeron variables externas debido a la alta correlación entre ellas y la liquidez lo que generó problemas de multicolinealidad, prueba que viola uno de los supuesto técnicos, a pesar de las transformaciones fue necesario extraerlas del modelo, mejorando su ajuste.
- **El presente modelo no sustituye la construcción de un índice:** el modelo solo pretende identificar la influencia de las variables endógenas financieras que afectan la liquidez total de la economía, prestando mayor atención a las que impactan en mayor medida a su resultado; será conveniente explorar la construcción de un índice por medio del análisis de componentes principales (ACP) que detecta el peso de cada variable en una relación lineal, medida por componentes principales los cuales indican cual explica la mayor varianza en el modelo.
- **El presente modelo debe construirse a una escala periódica de menor frecuencia:** debido a la disponibilidad de información de algunas variables de forma anual el modelo de construyó respondiendo a dicho periodo de referencia, no

obstante se recomienda diseñar en una escala menor de tiempo, al menos trimestral para que pueda cumplir la labor de enviar alertas del comportamiento de la liquidez de la economía.

- **El modelo simplifica el peso de algunas variables endógenas:** a pesar de la validez estadística del modelo, éste no pretende menospreciar el aporte de muchas otras variables que pueden jugar un impacto importante en el riesgo, sin embargo es un acercamiento de referencia a medir sensibilidad.

3.4. Método de mínimos cuadrados

Este apartado toma las referencias de las citas y marco teórico de [Wackerly,] para exponer los aspectos técnicos del modelo de método de mínimos cuadrados para una regresión lineal simple pero con posibilidad de ampliarse a una múltiple.

Un procedimiento para estimar los parámetros de cualquier modelo lineal, el método de mínimos cuadrados, se puede ilustrar con sólo ajustar una recta a un conjunto de puntos. Suponga que deseamos ajustar el modelo:


$$E(Y) = \beta_0 + \beta_1 x$$

al conjunto de puntos que se muestra para el modelo. [La variable independiente x podría ser w^2 o $(w)^{1/2}$ o $\ln w$, etc., para alguna otra variable independiente w .] Esto es, postulando que $Y = \beta_0 + \beta_1 x + \varepsilon$, donde ε tiene alguna distribución de probabilidad con $E(\varepsilon) = 0$. Si $\hat{\beta}_0$ y Si $\hat{\beta}_1$ son estimadores de los parámetros β_0, β_1 , entonces $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x$ es claramente un estimador de $E(Y)$.

El procedimiento de mínimos cuadrados para ajustar una recta que pase por un conjunto de n puntos es semejante al método que podríamos usar si ajustamos una recta a simple vista; esto es, deseamos que las diferencias entre los valores observados y los puntos

correspondientes en la recta ajustada sean “pequeñas” en un sentido general. Una forma cómoda de lograr esto y que proporciona estimadores con buenas propiedades, es minimizar la suma de cuadrados de las desviaciones verticales a partir de la recta ajustada (vea las desviaciones indicadas en la figura 1).

Figura 1: Ajuste de una recta que pasa por un conjunto de puntos



Fuente: Estadística Matemática con Aplicaciones. Wackerly y Sheaffer

Entonces, si

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

es el valor pronosticado del i -ésimo valor y (cuando $x = x_i$), entonces la desviación (a veces llamada error) del valor observado de y_i a partir de $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ es la diferencia $y_i - \hat{y}_i$ y la suma de los cuadrados de las desviaciones a minimizar es

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n \left[y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i) \right]^2$$

La cantidad **SSE** también recibe el nombre de suma de cuadrados del error por razones que más adelante se harán evidentes. Si la **SSE** tiene un mínimo, ocurrirá para valores de β_0 y β_1 que satisfagan las ecuaciones, $\partial SSE / \partial \hat{\beta}_0 = 0$ y $\partial SSE / \partial \hat{\beta}_1 = 0$. Tomando las derivadas parciales de la **SSE** con respecto a $\hat{\beta}_0$ y $\hat{\beta}_1$ e igualando a cero, obtenemos:

$$\frac{\partial SSE}{\partial \hat{\beta}_0} = \frac{\partial \left\{ \sum_{i=1}^n \left[y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i) \right]^2 \right\}}{\partial \hat{\beta}_0} = - \sum_{i=1}^n 2 \left[y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i) \right] = -2 \left(\sum_{i=1}^n y_i - n \hat{\beta}_0 - \hat{\beta}_1 \sum_{i=1}^n x_i \right) = 0$$

y

$$\frac{\partial SSE}{\partial \hat{\beta}_1} = \frac{\partial \left\{ \sum_{i=1}^n \left[y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i) \right]^2 \right\}}{\partial \hat{\beta}_1} = - \sum_{i=1}^n 2 \left[y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i) \right] x_i = -2 \left(\sum_{i=1}^n x_i y_i - \hat{\beta}_0 \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n x_i^2 \right) = 0$$

Las ecuaciones $\partial SSE / \hat{\beta}_0 = 0$ y $\partial SSE / \hat{\beta}_1 = 0$ se denominan ecuaciones de mínimos cuadrados para estimar los parámetros de una recta. Las ecuaciones de mínimos cuadrados son lineales en $\hat{\beta}_0$ y $\hat{\beta}_1$ y por tanto pueden resolverse simultáneamente. Puede verificar que las soluciones son:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n y_i}{\sum_{i=1}^n x_i^2 - \frac{1}{n} (\sum_{i=1}^n x_i)^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Además, se puede demostrar que la solución simultánea para las dos ecuaciones de mínimos cuadrados da valores de $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimizan la SSE. Dejamos esto para que lo compruebe. Las expresiones son las siguientes:

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \text{ y } \sum_{i=1}^n (x_i - \bar{x})^2$$


Estas expresiones se usan para calcular $\hat{\beta}_1$ se encuentran a menudo en el desarrollo de modelos de regresión lineal simple. La primera de éstas se calcula al sumar productos de valores x menos su media y valores y menos su media, denotando esta cantidad por S_{xy} . Del mismo modo, denotaremos la segunda cantidad por S_{xx} porque se calcula al sumar productos que contienen únicamente los valores x . Los estimadores de mínimos cuadrados para el modelo de regresión lineal simple:

$$1. \hat{\beta}_1 = \frac{S_{xy}}{S_{xx}}, \text{ donde } S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \text{ y } S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$

$$2. \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

En términos gráficos el modelo de regresión lineal múltiple se observa de la siguiente manera:

Figura 2: Gráfico de un modelo de regresión múltiple



Fuente: Estadística Matemática con Aplicaciones. Wackerly y Sheaffer


4. Principales Resultados del Modelo

4.1. Correlaciones de las variables

En las pruebas previas a la corrida del modelo fue importante estimar las correlaciones bivariadas de cada una de las variables que conformaron la base original de los indicadores empleados en el análisis, se pueden

observar en la figura 3. Aproximadamente se cargaron 25 variables en la base de datos, la fuente principal de dicha información se encontró en el sitio WEB de la Superintendencia del Sistema Financiero SSF y el Banco Central de Reserva de El Salvador BCR. Es importante destacar que se construyó una serie desde el año 2004 al 2018, es decir que se determinó un periodo de 15 años.

Figura 3: Correlaciones parciales de las variables del modelo



Fuente:Elaboración propia conforme a la base de datos de indicadores

Las variables que mostraron en sus resultados altas correlaciones fueron por ejemplo: *patrimonio*(-0,785), *eficiencia*(0,730), *M1*(0,931), *Deuda*(0,883), *PIBusa*(0,952), *Transferencias*(0,9714) y *PIB*(0,958); lamentablemente muchas de ellas se tuvieron que desechar porque las pruebas de los supuestos de colinealidad no se cumplieran, a pesar de realizar algunas transformaciones algunas de ellas. La colinealidad es un problema cuando una dimensión o factor con un índice de condición alto, contribuye a explicar gran cantidad de la varianza de los coeficientes de dos o más

variables. Se emplearon variables con baja correlación en algunos casos para entrar al análisis del modelo para evitar infringir éste supuesto. Las variables que atendieron las pruebas finales para estimar el modelo fueron: Liquidez, Patrimonio, Morosidad y Riesgo, que más adelante se explican que ratios comprenden.

4.2. Resumen del modelo

El modelo presento la siguiente tabla resumen de pruebas y estadísticos importantes, ver figura No. 4

Figura 4: Resumen del modelo
OLS Regression Results

Dep. Variable:	LiquidezTotal	R-squared:	0.950
Model:	OLS	Adj. R-squared:	0.930
Method:	Least Squares	F-statistic:	47.37
Date:	Fri, 03 Jan 2020	Prob (F-statistic):	1.82e-06
Time:	22:15:34	Log-Likelihood:	-112.31
No. Observations:	15	AIC:	234.6
Df Residuals:	10	BIC:	238.2
Df Model:	4		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
Intercept	7973.3843	2489.433	3.203	0.009	2426.583	1.35e+04
r_liquidez	328.8745	85.695	3.838	0.003	137.933	519.816
r_patrimonio	-149.9215	11.690	-12.825	0.000	-175.968	-123.875
np.log(r_morosidad1)	-8536.8702	1361.455	-6.270	0.000	-1.16e+04	-5503.358
base.r_riesgo1	730.9542	170.435	4.289	0.002	351.201	1110.707

Omnibus:	1.621	Durbin-Watson:	1.813
Prob(Omnibus):	0.445	Jarque-Bera (JB):	0.268
Skew:	0.198	Prob(JB):	0.875
Kurtosis:	3.521	Cond. No.	749.

Warnings:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Fuente:Elaboración propia conforme a la base de datos de indicadores

En una primera revisión general los indicadores que muestra el modelo son muy buenos por ejemplo, presenta una correlación ajustada de $R^2 = 0,930$, lo que indica que las variables explicativas definen bien a la variable explicada en éste caso a la Liquidez Total país. Todas las variables que explican a la variable dependiente son significativas, es decir por abajo o iguales a un P valor de 0.05; Las pruebas de los

supuestos como el caso de Durbin Watson para medir la independencia de los residuos muestra un resultado de 1,813, según la teoría este debe de permanecer entre los valores de 1,5 y 2,5 para establecer independencia de los residuos. La prueba de Jarque-Bera (JB) registra un valor cercano a 0 de 0,268 demuestra normalidad de los residuos. La ecuación del modelo calculado es la siguiente:

$$\theta = 7973,38 + \beta_{liquidez}(328,87) + \beta_{patrimonio}(-149,92) + \beta_{log(morosidad)}(-8536,87) + \beta_{riesgo}(730,95)$$

a donde:

θ = Liquidez Total de la Economía (M1 + Cuasidinero)

$\beta_{liquidez}$ = Razón de coeficiente de liquidez neta bancos

$\beta_{patrimonio}$ = Razón de inmovilización de patrimonio neto bancos

$\beta_{log(morosidad)}$ = Logaritmo de la Razón de morosidad de la cartera bancos


β_{riesgo} = Razón de riesgo crediticio bancos

4.3. Resultado de los test de supuestos del modelo

La prueba de normalidad de los residuos se muestra a continuación en la figura 5, el resultado de la prueba

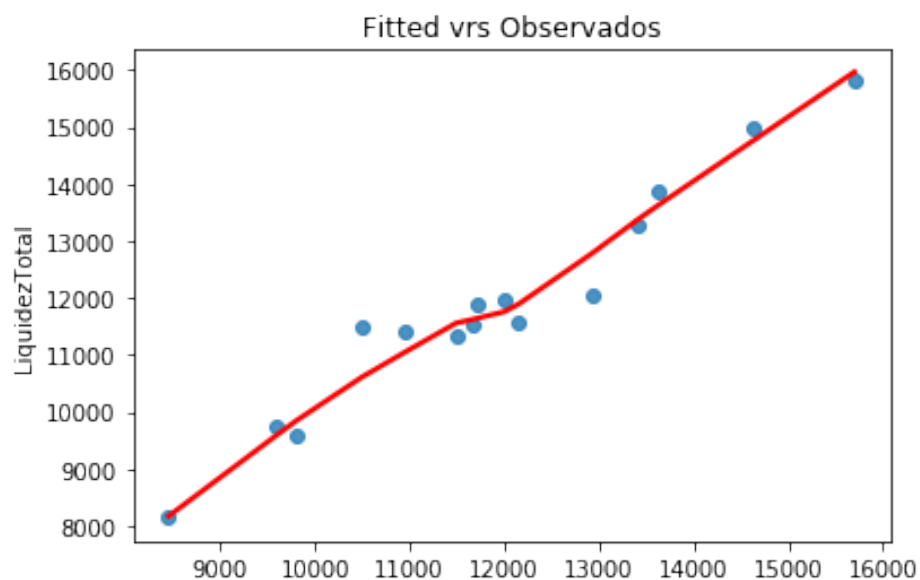
de Shapiro Wilk es superior a nuestro P valor por lo que se define un comportamiento normal de los residuos, así como lo confirma gráficamente la tendencia; además la figura 6 muestra una tendencia de linealidad:

Figura 5: Test de Normalidad de los Residuos



Fuente:Elaboración propia conforme a la base de datos de indicadores

Figura 6: Test de Linealidad de los Residuos

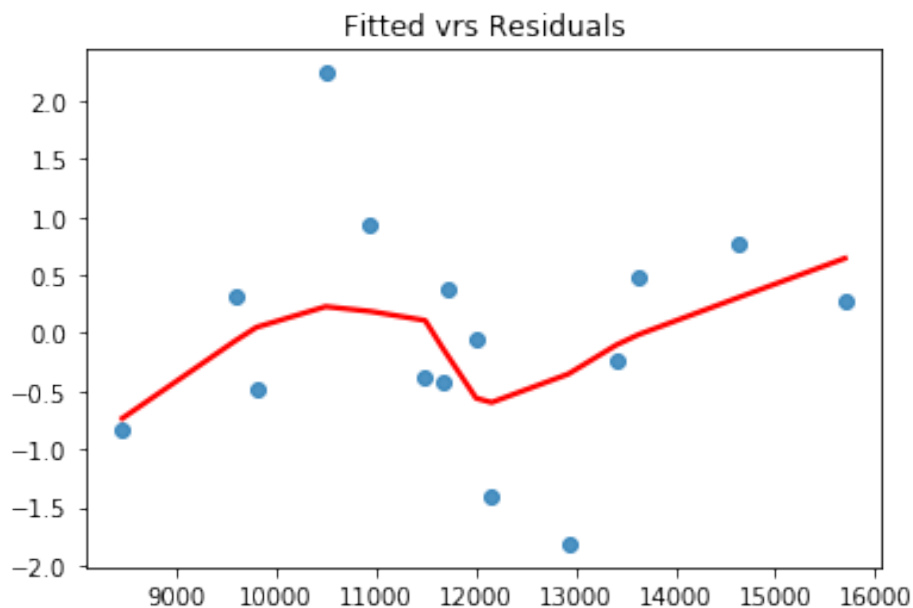


Fuente:Elaboración propia conforme a la base de datos de indicadores

Se muestra en las figuras 7 y 8 los resultados de las pruebas de homocedasticidad y de influencia, indican que puede existir una observación que sale de la varianza constante lo que puede ser permisible pero es de hacer revisiones posteriores, la homocedasticidad indica que por cada valor de la


variable independiente (o combinación de valores de las variables independientes), la varianza de los residuos es constante; los valores VIF para detectar colinealidad no sobrepasan las 15 unidades, el test de Breuschpagan indica que no hay presencia de homocedasticidad con un p valor de 0.6269 corroborando la tendencia gráfica.

Figura 7: **Test de Homocedasticidad**



Fuente:Elaboración propia conforme a la base de datos de indicadores

Figura 8: **Test de influencia**




Fuente:Elaboración propia conforme a la base de datos de indicadores

La predicción del modelo versus los datos estimados se puede observar en la siguiente figura 9, por ejemplo el valor del modelo para el periodo 15 o año 2018 es de US\$ 15,697 y el dato real es de US\$ 15,804, se registra como muy precisa; El año 2017 reportó para el modelo US\$ 14,626 y los datos reales se definieron


en US\$ 14,979; a manera de ejemplo retomando una de las variables que entran al modelo las estimaciones por ejemplo para liquidez versus sus predictores estandarizados y errores muestran una tendencia muy buena, lo que se puede observar en la figura 10.

Figura 9: Valores del modelo versus los predictivos
Modelo vrs Datos



Fuente:Elaboración propia conforme a la base de datos de indicadores

Figura 10: Valores del modelo versus los predictivos de liquidez
Fitted values versus Liquidez



Fuente:Elaboración propia conforme a la base de datos de indicadores

5. Discusión

Como se muestra en resumen del diagnóstico del sistema monetario realizado por el BCR y expuesto en la investigación citada en [De García et al., 2018], el sistema monetario de El Salvador se vuelve muy complejo, desde el desarrollo e implementación de la dolarización, en automático se instauran mecanismos de control y seguimiento hacia los agentes que conforman todo el sistema financiero nacional debido a que la política monetaria se traslada o adapta a la disponibilidad de liquidez de los Bancos privados por ser captadores del dólar en el mercado de dinero que interactúan con la economía doméstica y otras economías cuyos agentes jurídicamente residen en el exterior.

Los bancos también juegan un papel en el mercado de dinero como agentes operadores de canalizar parte del pago de la deuda nacional, registrado en la cuenta de capital de balanza de pagos y como impacto directo la emisión pura del papel moneda y la instauración de las tasas de interés de referencia pasan a manos de la Reserva Federal de los Estados Unidos; prácticamente el BCR luego de tener mayor autonomía y músculo en la economía nacional como protagonista directo de la política monetaria, posterior a la dolarización pasa a ser junto con la SSF a conformarse en agentes más vigilantes y reguladores de ese nuevo escenario adoptado en el sistema financiero.

El desarrollo de todo el sistema financiero ha sido muy bueno y acelerado desde los registros que se poseen con toda la entrada de la reforma normativa en la década de los 90s da pie a la apertura de un mayor desarrollo del sistema financiero, por ejemplo éste sistema actualmente cubre más entes en su totalidad, dichos agentes dinamizan los siguientes subsistemas financieros: Bancos, Bursátiles, Previsionales, Organizaciones auxiliares, Bancos Cooperativos, Federaciones y Sociedades de Ahorro y Crédito, Instituciones Públicas de Crédito, Sociedades de Garantía Recíproca, Sociedades de Seguros y Casas de Cambio en Moneda Extranjera.

El dólar tiende a crear estructuras de inversión

volátiles por la alta especulación que genera ser la moneda de referencia o moneda fuerte en las transacciones mundiales, sin embargo ha desarrollado también eventos importantes en la economía doméstica de Estados Unidos y los mercados mundiales, causando shocks externos, tal como sucedió en la crisis financiera mundial del 2008 y otras previas en la zona de Asia, esta realidad provoca que sus principales socios comerciales de USA, como es el caso de nuestro país, también amarrado a una fuerte relación de transferencias monetarias por medio de las remesas que envía la PEA Salvadoreña desde los Estados Unidos y el esquema de Deuda pública y privada anclada al dólar, justifican que el seguimiento de la estabilidad financiera sea exhaustiva por parte del Banco y que la disposición de la liquidez del sistema financiero sea clave; posterior a las crisis financieras mundiales que se han suscitado, se han adoptado un conjunto de fuertes normativas internacionales auspiciadas por los entes financieros mundiales como por ejemplo el FMI y BIS.

Dicha normativa de los entes financieros se ha enfocado a evitar a toda costa el riesgo sistémico debido a que todo el sistema financiero a escala mundial ahora esta conectado y posee muchas redes de propagación y de contagio en una fuerte crisis. De esa situación El Salvador no se escapa y debe estar atento a disminuir a toda costa dicho riesgo sistémico más aun en el esquema dolarizado que imposibilita a veces parcialmente a adoptar mecanismos de ajuste al sistema por la ausencia directa de emanar la política monetaria y depende más de vigilar y regular dicho riesgo provisto por la disponibilidad de liquidez del sistema financiero local.

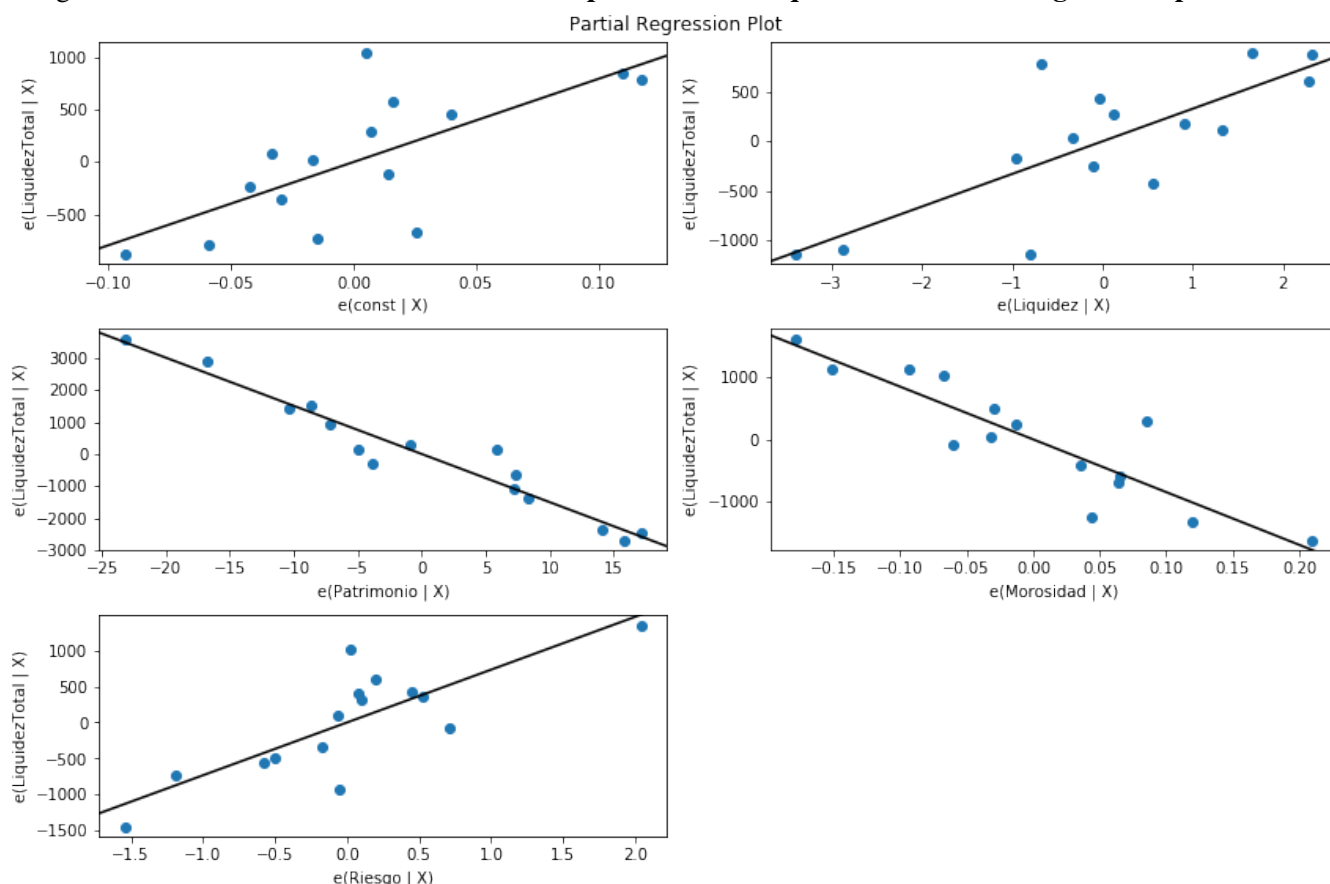
Ahora bien como se conoce, es difícil construir un indicador multidimensional que mida los diferentes componentes que conforman el riesgo sistémico, pero sin embargo no es imposible, éste modelo pretende muy modestamente iniciara a medir sensibilidades en las variables endógenas de los bancos lo que da pie a que sea ampliado y mejorado, además aporta un complemento a la construcción de otro indicador más integral que abarque o aplique una visión más analítica y multivariante como por ejemplo se puede mencionar el cálculo de Componentes Principales (ACP), regresión logística, entre otras técnicas, que son posibles aplicar

en un ambiente de Big Data o Machine Learning por medio de potentes lenguajes de programación estadística y científica como por ejemplo lenguaje R y Python.

Debido al alto volumen, volatilidad y variabilidad de

la información que generan los Bancos y todo el sistema es importante adoptar ya modelos más avanzados de seguimiento del riesgo sistémico; a continuación los principales hallazgos del modelo se reflejan en la figura 11.

Figura 11: Variables normalizadas versus los predictivos de liquidez en forma de regresiones parciales



Fuente:Elaboración propia conforme a la base de datos de indicadores

La figura 11 es importante porque denota la tendencia que posee la liquidez total de la economía frente a un comportamiento de las variables endógenas a nivel de los ratios financieros de los bancos; la liquidez de la economía alcanzó para el 2018 un estimado de US\$ 15,804 millones incluido la masa monetaria M1 más el cuasidínaro, por ejemplo uno de los principales hallazgos del modelo en la medición de sensibilidad es que la variable de liquidez total se verá incrementada si el coeficiente de liquidez neta de los bancos camina hacia el aumento, esto es positivo porque la sanidad financiera de los Bancos es buena por ejemplo para

el 2018 éste ratio registró según fuentes de la SSF un valor de 32.96 en términos ácidos, es decir que poseen una alta liquidez. Sin embargo la relación no liquida es decir, la condición dura o bruta de activos entre pasivos da una relación de 1.10 aproximadamente, esto es decir que se encuentra al filo de la respuesta de exigencia de los acreedores, además en otros aspectos relevantes el 78%, representan los depósitos con respecto a la liquidez del sistema en su totalidad, esto es importante porque indica que en la estructura del sistema financiero una salida en manada o salida de capital por pánico especulativo obligaría a tomar medidas de restricción de

retiros o medidas como el famoso “*corralito*” aunque en el modelo no es la más significativa debido a que el efecto multiplicador frente a los préstamos anularía su efecto, sin embargo es importante darle mucho seguimiento.

Es de poner atención a la razón de liquidez por otra poderosa razón, el 24%, de la masa monetaria total la representa el M1, esto es significativo porque ante una reducción significativa de la liquidez total afectaría principalmente a este agregado, generando una alta restricción de retiros y pagos en el sistema lo que provocaría un riesgo sistémico, además indica que los Bancos están concentrando su dinámica económica en valores, títulos, o instrumentos financieros de no muy veloz convertibilidad o el llamado cuasidinero, lo cual puede tener una interpretación de que sus inversiones pueden estar siendo concentradas en activos de mayor rentabilidad en el exterior pero con altos riesgos lo que indica una baja liquidez o extensión en el agregado M1.

Continuando con el hilo conductor del análisis del modelo, se muestra otro hallazgo importante ante la tendencia de la liquidez, que es significativa también y esta es la razón financiera de la inmovilización del patrimonio producto de activos de difícil convertibilidad o incobrables, este resultado impacta negativamente la liquidez de la economía según el modelo, porque la capacidad de respuesta de conversión de este factor genera una baja en la liquidez porque tiene en su interior el saniamiento de cuentas incobrables absorbidas por la capacidad patrimonial que impide, introducir más líquido a los agregados monetarios en la economía, al contrario le resta capacidad al sistema, en el modelo posee un importante peso incluso mayor al de la razón de liquidez porque explica mayor varianza en la suma de los errores de estimación del modelo; muchas de la dinámica de las garantías hipotecarias tienen mucho que ver en este caso, esas son las interrogantes que deben ser mayormente investigadas.

La razón de morosidad transformada logarítmicamente implica una de las variables también con mayor peso significativo en la varianza en el modelo, sin embargo esa transformación se debió a que el modelo ya daba pequeños indicios de colinealidad debido a su relación

final o impacto en el patrimonio si muchos de estos saldos son sanitados; pero fue incluida porque con su transformación le daba mejor bondad de ajuste al modelo mejorando las correlaciones y eliminando el efecto de colinealidad entre ellas según lo evidencia las pruebas o test estadísticos finales; en el razonamiento económico esta razón de morosidad al aumentar o incrementarse tiene un impacto negativo en la liquidez del sistema, según lo evidencia la figura 11 en términos normalizados, es decir, que al tener menor pagos o respuesta a sus créditos esto contrae el coeficiente de expansión crediticia, incorporando menor liquidez al sistema porque restringe esa relación o efecto multiplicador que se explica en la siguiente fórmula:

$$x = \frac{d(1 - c)}{1 - k(1 - c)}$$

a donde:

x = Expansión crediticia máxima que puede general el banco a partir del dinero depositado

d = El dinero depositado en la caja del banco

c = Coeficiente de caja que mantiene el banco para poder hacer frente a sus compromisos

k = La proporción de los préstamos concedidos no es dispuesto por los prestatarios

Por ejemplo con un coeficiente del 10 por ciento, permitiría como máximo la creación de créditos nueve veces superior al depósito originariamente creado, por tanto, multiplicaría por diez la oferta monetaria.

Esto explica en muchas veces la parte inquisitiva de muchos Bancos en la recuperación de la mora, sin embargo a la luz del modelo económico evidencia un aporte positivo a la tendencia de la liquidez, disminuyendo el riesgo sistémico; la lógica bancaria es económica y se encamina hacia ese comportamiento tratando de disminuir en mayor parte la cobertura de saniamiento patrimonial de las cuentas incobrables o el aumento de activos inmovilizados, lo que ya se observó deprime la liquidez del sistema aumentado el riesgo sistémico.

Finalmente en el análisis de las variables incorporadas al modelo, se desprende que el comportamiento de aumentar el riesgo crediticio o el

apetito a la alta rentabilidad con altas tasas de intereses de por medio pero con demasiados componentes volátiles, implica una mayor inyección a la liquidez económica, tal como lo muestra la figura 11, sin embargo, este comportamiento es pernicioso para el sistema financiero, aunque disminuya la restricción de liquidez a la larga esta puede revertirse por la poca recuperabilidad de las cuentas y desembocará en la disminución de la liquidez económica y por ende en aumentar el riesgo sistémico, siendo importante vigilar a los bancos en su accionar; dichas acciones pueden estar impulsadas a que la liquidez ácida bancaria es alta y necesitan poner en movimiento muchos de los activos convertible y reciclarlos constantemente para generar más ganancia aunque sea progresivamente.

Un aspecto con el que se cierra éste análisis es que la sensibilidad al riesgo sistémico en el sistema financiero nacional, viene dado también por el latente riesgo de contagio o propagación de éste, uno de los factores que puede influir mucho en ello es el nivel de concentración del sector financiero, por ejemplo en el estudio se midió su concentración utilizando el Índice Herfindahl-Hirschman, retomado de [Zurita et al., 2014]:

$$HHI = \sum_{i=1}^N S_i^2$$

a donde:

S_i^2 = Es la cuota de mercado de la i-ésima entidad

N = Es el número de entidades del mercado

Calculado para los depósitos de los bancos, los parámetros de referencia que se tienen son los siguientes: (1) de Menor de 100: Mercado muy competitivo, (2) Entre 100 y 1.500: Mercado desconcentrado, (3) Entre 1.500 y 2.500: Mercado concentrado, (4) Más de 2.500: Mercado altamente concentrado. Para los cálculos elaborados para el sistema financiero local con información de la SSF, se detectó una alta concentración en el año 2012 y 2013,

explicado por poca presencia de entidades bancarias, con un valor en el índice de Herfindahl-Hirschman de 2,588 y 2,606 respectivamente.

Actualmente para el año 2018 se denota nuevamente una concentración dado que el valor del índice dió como resultado 2,102, la explicación a ello y a que la vez preocupa en los componentes de seguimiento del riesgo sistémico es que de las 14 instituciones bancarias casi dos cuartas partes concentra el 80%, de los activos y pasivo de todo el sistema financiero, recordando que éstos representan más del 77%, de los agregados monetarios que conforman la liquidez de la economía, nos referimos a los siguientes bancos: **Agrícola, Davivienda, América Central, Scotiabank, Cuscatlán y Promerica**. Cuatro de esos bancos concentran el 65%, de los depósitos, exigiendo una mayor vigilancia de su sanidad financiera como ya se observó, todas estos factores podrían repercutir en un riesgo sistémico hacia todo el sistema financiero la caída o problemas de eventos significativos en 4 bancos pudiera desatar un alto contagio o propagación de una crisis de liquidez, es importante monitorear y desconcentrar el sector para disminuir el riesgo sistémico.

Por ejemplo en un escenario hipotético calculado con las variables del modelo, explica que una caída en la liquidez neta al 25, un aumento del ratio de la inmovilización patrimonial de 12.5 puntos, así como una razón de 1.69 de morosidad y un ratio en el riesgo de 2.17, podría ocasionar una caída de la liquidez total de la economía en un 25%, impactando de forma inmediata al agregado monetario M1, ocasionando altas restricciones de retiro de depósitos o problemas de pagos, entrando a las puertas de un riesgo sistémico, por eso es importante el monitoreo de todas las variables a un periodo de menor frecuencia y la construcción de un indicador multidimensional que cubra más áreas que son latentes para que el riesgo sistémico se propague.

Referencias

- [Angulo Duque, 2015] Angulo Duque, D. (2015). Análisis del riesgo sistémico: propuesta de un modelo predictor de crisis.
- [Betancourt Bejarano et al., 2013] Betancourt Bejarano, K., García Díaz, C. M., and Lozano Riaño, V. (2013). Teoría de markowitz con metodología ewma para la toma de decisión sobre cómo invertir su dinero. *Atlantic Review of Economics*, 1.
- [De García et al., 2018] De García, Y. D., Arévalo, J. O., and Hernández, A. A. (2018). Fundamentos económicos del sistema monetario en el salvador. *Foro de Investigadores de Bancos Centrales del Consejo Monetario Centroamericano*.
- [Hansen, 2013] Hansen, L. P. (2013). Challenges in identifying and measuring systemic risk. In *Risk topography: Systemic risk and macro modeling*, pages 15–30. University of Chicago Press.
- [VanderPlas, 2016] VanderPlas, J. (2016). *Python data science handbook: essential tools for working with data*. O'Reilly Media, Inc."
- [Wackerly,] Wackerly, M. Sheafer.(2008). *Estadística Matemática con Aplicaciones. 7ma Edición. Cengage. Learning*.
- [Zurita et al., 2014] Zurita, J. et al. (2014). Análisis de la concentración y competencia en el sector bancario. *Madrid, España. Recuperado el*, 30.

ModeloBCR

January 4, 2020

1 ANEXO: Modelo para estimar sensibilidad riesgo sistémico

```
[2]: #=====
#=====Modelo de regresion para estimar riesgo sistémico=====
#=====

#---cargando las librerias

from statsmodels.compat import lzip

import numpy as np
import pandas as pd
import statsmodels.formula.api as smf
import statsmodels.stats.api as sms
import statsmodels.stats.api as sm
import matplotlib.pyplot as plt
import seaborn as sns
```

```
[6]: #---Cargando la base de datos

base=pd.read_excel('F:\CONSULTORIAS\Financiero\Para Prueba\ModeloBCR_Py\Base.
→xlsx', 'Hoja1', index_col=None, na_values=['NA'])
base.head(3)
```

```
[6]: Corr    Año  r_liquidez  r_solvenscia1  r_solvenscia2  r_morosidad1  \
0      1  2004      36.07      13.40      9.56      2.33
1      2  2005      33.47      13.53     10.17      1.92
2      3  2006      32.25      13.79     10.66      1.92

      r_morosidad2  r_riesgo1  r_patrimonio  r_cartera  ...  r_rentabilidad2  \
0      132.32      2.86      41.68      5.95  ...      1.02
1      126.67      2.39      35.74     10.95  ...      1.18
2      116.38      2.19      33.49     12.91  ...      1.50

      LiquidezTotal      M1  Concentracion      Deuda  PIB_Usa  \
0      8137.054188  1361.271042  1870.755124  6050.42  14406.4
1      9581.413594  1455.230981  1870.755124  6456.04  14912.5
```

```
2      9729.804630  1656.465542    1869.367696  7033.08  15338.3
```

```

      Transferencias  CuentaCorri      PIB  Reservas
0          2547.6      -541.58  8167.72  1886.761
1          3017.3      -527.99  8458.70  1827.954
2          3470.8      -668.76  8789.62  1905.801

```

```
[3 rows x 24 columns]
```

```
[11]: #----Comprobando las correlaciones
d=base.corr()
d.head(3)
```

```
[11]:
      Corr      Año  r_liquidez  r_solvensia1  r_solvensia2  \
Corr      1.000000  1.000000  -0.367495      0.663462      0.795556
Año      1.000000  1.000000  -0.367495      0.663462      0.795556
r_liquidez -0.367495 -0.367495      1.000000      0.098758     -0.147376

      r_morosidad1  r_morosidad2  r_riesgo1  r_patrimonio  r_cartera  \
Corr      -0.133428      0.014652  -0.215537     -0.895597     -0.174907
Año      -0.133428      0.014652  -0.215537     -0.895597     -0.174907
r_liquidez  0.815641     -0.584228  0.876027      0.679900     -0.730445

      ...  r_rentabilidad2  LiquidezTotal      M1  Concentracion  \
Corr      ...      -0.057125      0.938111  0.984309     -0.109728
Año      ...      -0.057125      0.938111  0.984309     -0.109728
r_liquidez ...      -0.414551     -0.265121 -0.242320     -0.227321

      Deuda  PIB_Usa  Transferencias  CuentaCorri      PIB  \
Corr      0.985053  0.962211      0.925739     -0.098889  0.970463
Año      0.985053  0.962211      0.925739     -0.098889  0.970463
r_liquidez -0.353619 -0.478283     -0.432111      0.479074 -0.420502


      Reservas
Corr      0.838345
Año      0.838345
r_liquidez 0.001662

```

```
[3 rows x 24 columns]
```

```
[16]: #--Graficando las correlaciones
f, ax = plt.subplots(figsize=(9, 6))
sns.heatmap(d, annot=True,linewidths=.5, ax=ax)
```

```
[16]: <matplotlib.axes._subplots.AxesSubplot at 0x160946f7710>
```



```
[5]: ##guardando las correlaciones
d.to_excel('F:\CONSULTORIAS\Financiero\Para Prueba\ModeloBCR_Py\Correlaciones.
→xlsx', sheet_name='Corr')
```

```
[55]: ##Creando el modelo
results2=smf.ols('LiquidezTotal ~ r_liquidez+r_patrimonio+np.
→log(r_morosidad1)+base.r_riesgo1', data=base).fit()
print(results2.summary())
```

OLS Regression Results

```
=====
Dep. Variable:          LiquidezTotal    R-squared:                0.950
Model:                  OLS              Adj. R-squared:         0.930
Method:                 Least Squares    F-statistic:             47.37
Date:                   Fri, 03 Jan 2020  Prob (F-statistic):       1.82e-06
Time:                   22:15:34         Log-Likelihood:          -112.31
No. Observations:      15              AIC:                   234.6
Df Residuals:          10              BIC:                   238.2
Df Model:               4
Covariance Type:        nonrobust
=====
=====
```

	coef	std err	t	P> t	[0.025

Intercept	7973.3843	2489.433	3.203	0.009	2426.583
1.35e+04					
r_liquidez	328.8745	85.695	3.838	0.003	137.933
519.816					
r_patrimonio	-149.9215	11.690	-12.825	0.000	-175.968
-123.875					
np.log(r_morosidad1)	-8536.8702	1361.455	-6.270	0.000	-1.16e+04
-5503.358					
base.r_riesgo1	730.9542	170.435	4.289	0.002	351.201
1110.707					
=====					
Omnibus:	1.621	Durbin-Watson:			1.813
Prob(Omnibus):	0.445	Jarque-Bera (JB):			0.268
Skew:	0.198	Prob(JB):			0.875
Kurtosis:	3.521	Cond. No.			749.
=====					

Warnings:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

```
[31]: #--Normalidad
#--Prueba Jarque Bera
name = ['Jarque-Bera', 'Chi^2 two-tail prob.', 'Skew', 'Kurtosis']
test = sms.jarque_bera(results2.resid)
lzip(name, test)
```

```
[31]: [('Jarque-Bera', 0.2681612528329159),
      ('Chi^2 two-tail prob.', 0.8745195523831674),
      ('Skew', 0.1983912155992784),
      ('Kurtosis', 3.5211733942027625)]
```

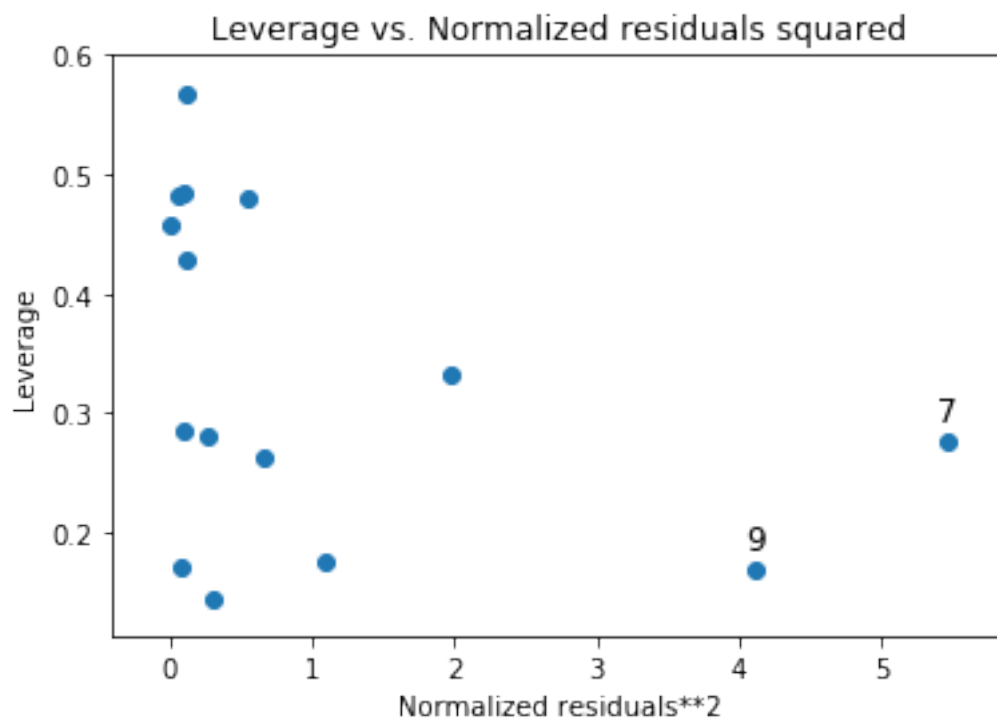
```
[32]: #--Normalidad
#--Omni test:
name = ['Chi^2', 'Two-tail probability']
test = sms.omni_normtest(results2.resid)
lzip(name, test)
```

```
[32]: [('Chi^2', 1.6211359053298857), ('Two-tail probability', 0.44460547963411146)]
```

```
[33]: #--Influence tests
from statsmodels.stats.outliers_influence import OLSInfluence
test_class = OLSInfluence(results2)
test_class.dfbetas[:,5,:]
```

```
[33]: array([[ 0.31903536, -0.24554504, -0.4004121 , -0.35298011,  0.56753893],
          [-0.03616643,  0.00947251, -0.17271616,  0.04536547,  0.03148353],
          [ 0.06586953, -0.05436694,  0.13274073, -0.0115668 , -0.00710033],
          [ 0.0773802 , -0.0061594 ,  0.16733956, -0.17863066,  0.06629673],
          [-0.33510091,  0.28245747, -0.11214244,  0.23649744, -0.3992023 ]])
```

```
[34]: from statsmodels.graphics.regressionplots import plot_leverage_resid2
fig = plot_leverage_resid2(results2, ax = ax)
```



```
[35]: #--Multicolinealidad
np.linalg.cond(results2.model.exog)
```

```
[35]: 749.3469829384873
```

```
[36]: #--Heteroskedasticity tests (Breush-Pagan test)
name = ['Lagrange multiplier statistic', 'p-value',
        'f-value', 'f p-value']
test = sms.het_breuschpagan(results2.resid, results2.model.exog)
lzip(name, test)
```

```
[36]: [('Lagrange multiplier statistic', 2.5991961965149013),
        ('p-value', 0.6269655208825462),
        ('f-value', 0.5239975242137991),
        ('f p-value', 0.720771021878027)]
```

```
[37]: #--Goldfeld-Quandt test
```

```
name = ['F statistic', 'p-value']  
test = sms.het_goldfeldquandt(results2.resid, results2.model.exog)  
lzip(name, test)
```

```
[37]: [('F statistic', 6.4207831458893025), ('p-value', 0.08241090881237588)]
```

```
[39]: resid_val=results2.resid  
fitted_val=results2.predict()  
results2.resid.mean()
```

```
[39]: 1.4430649268130462e-11
```

```
[40]: #-----Modelo 2
```

```
x=pd.DataFrame({'Liquidez':base.r_liquidez,'Patrimonio':base.  
→r_patrimonio,'Morosidad':np.log(base.r_morosidad1),'Riesgo':base.r_riesgo1})  
x.head(5)
```

```
[40]:
```

	Liquidez	Patrimonio	Morosidad	Riesgo
0	36.07	41.68	0.845868	2.86
1	33.47	35.74	0.652325	2.39
2	32.25	33.49	0.652325	2.19
3	34.04	29.94	0.717840	3.27
4	35.75	31.41	1.026042	7.39

```
[41]: y=base.LiquidezTotal
```

```
[42]: y
```

```
[42]: 0      8137.054188  
1      9581.413594  
2      9729.804630  
3     11392.453574  
4     11519.448172  
5     11551.871161  
6     11351.023372  
7     11504.248965  
8     11878.768493  
9     12049.560745  
10     11978.814525  
11     13290.486840  
12     13873.017266  
13     14979.032027  
14     15804.492767  
Name: LiquidezTotal, dtype: float64
```

```
[43]: import statsmodels.api as sm  
x_constant=sm.add_constant(x)  
Modelo=sm.OLS(y,x_constant).fit()  
Modelo.summary()
```

```
[43]: <class 'statsmodels.iolib.summary.Summary'>
      """
```

```

                                OLS Regression Results
=====
Dep. Variable:          LiquidezTotal      R-squared:          0.950
Model:                  OLS                Adj. R-squared:      0.930
Method:                 Least Squares       F-statistic:        47.37
Date:                   Fri, 03 Jan 2020     Prob (F-statistic):  1.82e-06
Time:                   21:16:58            Log-Likelihood:     -112.31
No. Observations:       15                 AIC:                234.6
Df Residuals:           10                 BIC:                238.2
Df Model:                4
Covariance Type:        nonrobust
=====
              coef      std err          t      P>|t|      [0.025      0.975]
-----
const          7973.3843    2489.433      3.203      0.009     2426.583     1.35e+04
Liquidez         328.8745      85.695      3.838      0.003      137.933     519.816
Patrimonio    -149.9215      11.690     -12.825      0.000     -175.968    -123.875
Morosidad   -8536.8702     1361.455      -6.270      0.000    -1.16e+04   -5503.358
Riesgo         730.9542     170.435      4.289      0.002      351.201     1110.707
=====
Omnibus:                 1.621    Durbin-Watson:           1.813
Prob(Omnibus):            0.445    Jarque-Bera (JB):         0.268
Skew:                     0.198    Prob(JB):                 0.875
Kurtosis:                 3.521    Cond. No.                  749.
=====
```

Warnings:


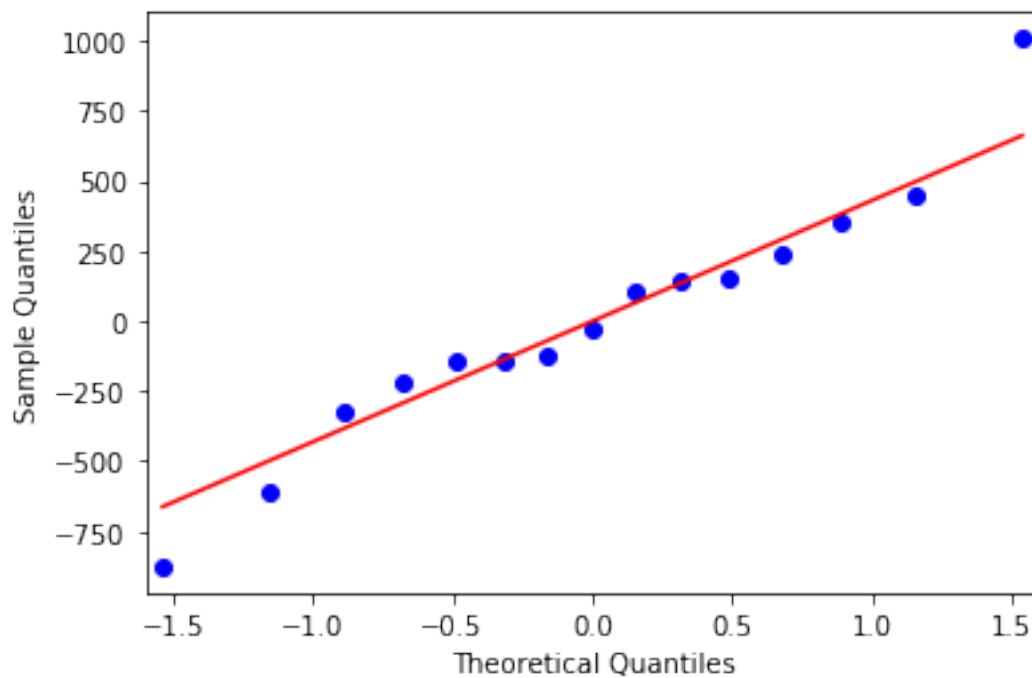
```
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
"""
```

```
[44]: residuos=Modelo.resid
      fitted=Modelo.predict()
      Modelo.resid.mean()
```

```
[44]: 1.418811734765768e-11
```

```
[45]: ##Normalidad
      from scipy import stats
      stats.shapiro(Modelo.resid)
      sm.qqplot(residuos,line='s')
```

```
[45]:
```




[46]: `stats.shapiro(Modelo.resid)`

[46]: (0.9715871214866638, 0.8808257579803467)



```
[47]: #--Linealidad
sns.regplot(x=fitted,y=y, lowess=True,line_kws={'color':'red'})
plt.title('Fitted vrs Observados')
```

```
[47]: Text(0.5, 1.0, 'Fitted vrs Observados')
```





```
[49]: #--Homocedasticidad
resid_stand=Modelo.get_influence().resid_studentized_internal
sns.regplot(x=fitted,y=resid_stand,lowess=True,line_kws={'color':'red'})
plt.title('Fitted vrs Residuals')
```

```
[49]: Text(0.5, 1.0, 'Fitted vrs Residuals')
```



```
[20]: --Influencia
fig,ax=plt.subplots(figsize=(12,8))
sm.graphics.influence_plot(Modelo,alpha=0.05,ax=ax,criterion='cooks')
```

[20]:



```
[50]: #---Homosedasticidad
bp_test=sms.het_breuschpagan(residuos,Modelo.model.exog)
print(bp_test)
print("Breuschpagan test: pvalue =",bp_test[1])
```


(2.5991961965148977, 0.6269655208825469, 0.5239975242137982, 0.7207710218780274)
Breuschpagan test: pvalue = 0.6269655208825469

```
[51]: #---Autocorrelacion
from scipy.stats.stats import pearsonr
x.columns
pearsonr(x['Liquidez'],Modelo.resid)
```

[51]: (4.6384637922934876e-14, 1.0)

```
[52]: sns.heatmap(x.corr(),annot=True)
```

[52]: <matplotlib.axes._subplots.AxesSubplot at 0x1bf9c925fd0>



```
[53]: #---Multicolinealidad
from statsmodels.stats.outliers_influence import variance_inflation_factor
vif=[variance_inflation_factor(x_constant.values,i) for i in range (x_constant.
    ↳shape[1])]
pd.DataFrame({'vif':vif[1:]}, index=x.columns).T
```

```
[53]:      Liquidez  Patrimonio  Morosidad    Riesgo  
vif    6.38154    2.199124   6.788268  10.510899
```

```
[ ]:
```